

META-HEURÍSTICAS

CCF-480

Prof. Dr. Marcus Henrique Soares Mendes
marcus.mendes@ufv.br
UFV - Campus Florestal

<http://lattes.cnpq.br/9729345585563115>

Roteiro

2

- Algoritmos Genéticos.
 - ▣ Fluxograma.
 - ▣ Representação.
 - ▣ População inicial.
 - ▣ Forma de geração.
 - ▣ Tamanho.
 - ▣ Função Fitness.

Algoritmos Genéticos

3



Fonte: Adaptado da referência (1).

marcus.mendes@ufv.br

Algoritmos Genéticos - Representação

4

- É a forma básica de traduzir a informação do nosso problema em um formato viável para o tratamento pelo computador.
- É o meio que o genótipo representa o fenótipo.
- Influencia:
 - ▣ Em como fazer as operações genéticas.
 - ▣ No desempenho do algoritmo genético.
 - ▣ Na possibilidade de gerar (ou não) soluções infactíveis.
 - ▣ Em determinar o quão perto soluções distintas (fenótipos) estão uma da outra.

Algoritmos Genéticos - Representação

5

□ Exemplo:

▣ Problema bin packing.

- Empacotar itens de diversos tamanhos utilizando o menor número de bins (pacotes) possíveis. Os pacotes têm uma certa capacidade.
- Representação 1
 - Para cada item, indique o número do seu pacote. Para criar o fenótipo (empacotamento real), percorre-se sequencialmente o genótipo é verificar em qual pacote colocar o item.
- Representação 2
 - O genótipo é uma permutação de itens. Para criar o fenótipo (empacotamento real), percorre-se sequencialmente o genótipo usando um heurística chamada First_Fit (põe o próximo item no primeiro pacote que ele couber).

Algoritmos Genéticos - Representação

6

□ Exemplo Bin Packing

▣ Representação 1

- Mais direta.
- Problemas:
 - muitas soluções inviáveis podem ser representadas.
 - muitas soluções com baixa qualidade podem ser representadas.

▣ Representação 2

- Indireta.
- Usar a heurística First_Fit envolve um custo computacional que pode ser caro.
- Muitas mudanças no genótipo podem não fazer diferença no fenótipo.
- Solução ótima pode não se representável.
- Resolve os problemas da representação 1.

Algoritmos Genéticos - Representação

7

- Formas de representação:
 - ▣ Codificação binária
 - Primeira forma empregada nos algoritmos genéticos.
 - Usada em problemas com variáveis contínuas ou discretas.
 - ▣ Codificação real
 - Usada em problemas com variáveis contínuas.
 - ▣ Vetores de inteiros
 - Usada em problemas com variáveis discretas.
 - ▣ Lista de regras
 - Usada em problemas de classificação.
 - Ex: problema do transformador
 - Concentração elemento químico a > valor1 && Concentração elemento químico b < valor2 então defeito_2 = 1
 - ▣ Qualquer estrutura de dados adequada ao problema em questão.

Algoritmos Genéticos - Representação

8

- Codificação binária
 - Utiliza um alfabeto de cardinalidade 2 (bit 0 ou 1).
 - A **cadeia de bits** (com comprimento l_i) para cada variável x_i do problema corresponde ao **cromossomo**.
 - A cadeia binária resultante da **concatenação** das **cadeias** de cada variável representa o **indivíduo**.
- Dado um problema de otimização de n variáveis com l_i bits para cada variável, tem-se que:
 - Cada indivíduo contém n cromossomos de tamanho l_i ($n \times l_i$ bits).
 - O **espaço de busca é discretizado em $2^{n \times l_i}$ soluções candidatas**.
 - Ex: problema com 3 variáveis de decisão e $l_i = 5$.

x_1 x_2 x_3
1 1 0 0 1 0 1 0 1 1 0 0 0 1 1

Algoritmos Genéticos - Representação

9

□ Codificação binária

- Dado um problema de otimização com n variáveis limitadas em $x_i^{min} \leq x_i \leq x_i^{max}$.
- Utilizando-se l_i bits para cada variável pode-se representar 2^{l_i} pontos no intervalo $[x_i^{min}, x_i^{max}]$.
- Assim, o intervalo é discretizado em $2^{l_i} - 1$ pequenos intervalos de tamanho (esse valor pode ser associado à precisão da variável i):

$$■ e_i = \frac{x_i^{max} - x_i^{min}}{2^{l_i} - 1}$$

Algoritmos Genéticos - Representação

10

□ Exemplo:

Transformar o valor de x_3 (0 0 0 1 1) da base 2 para base 10, sendo $x_{3\min} = -2$ e $x_{3\max} = 2.5$.

□ Qual o valor de e_i ?

$$\begin{aligned}x_3 &= -2 + (4.5/31)[1*2^0 + 1*2^1 + 0*2^2 + 0*2^3 + 0*2^4] \\ &= -2 + 0.145[3] = -1.565\end{aligned}$$

Algoritmos Genéticos - Representação

11

□ Codificação Binária

- Distância de hamming (d_h): entre dois números inteiros é definida como a quantidade de bits distintos na cadeia binária.
 - Ex: 0001 e 0111 têm $d_h(0001,0111) = 2$.
- Na codificação binária há o problema de **hamming cliffs**, isto é, há **diferenças consideráveis** do valor de d_h para **inteiros adjacentes**.
 - Ex: 0111 e 1000, que representam 7 e 8 em decimal, respectivamente. No código binário o valor de $d_h(0111,1000) = 4$.

Algoritmos Genéticos - Representação

12

□ Código Gray

- Se n_1 e $n_2 \in \{0, \dots, 2^{l_i} - 1\}$ são dois inteiros adjacentes representados no código Gray pelas cadeias binárias a_1 e a_2 de comprimento l_i então:
 - $|n_1 - n_2| = 1 \Rightarrow d_h(n_1, n_2) = 1$

□ Exemplo:

0	1	2	3	4	5	6	7	Valor
000	001	010	011	100	101	110	111	binário
000	001	011	010	110	111	101	100	Gray

Algoritmos Genéticos - Representação

13

- Conversão entre código binário e código Gray
 - Seja um cromossomo $b_i = (b_1, b_2, \dots, b_{l_i})$ no código binário e seu correspondente $G_i = (G_1, G_2, \dots, G_{l_i})$ no código Gray.
 - **A conversão entre o código binário e o código Gray, ou vice-versa, pode ser definida com base no operador “adição módulo 2” ou no operador “ou exclusivo”.**
 - $0 \oplus 0 = 0$
 - $0 \oplus 1 = 1$
 - $1 \oplus 0 = 1$
 - $1 \oplus 1 = 0$

Algoritmos Genéticos - Representação

14

- Algoritmo conversão entre código binário e código Gray.

```
n      //Número de bits da cadeia de caracteres
i      //Contador
G[n]   //Vetor que contém a cadeia de caracteres no código Gray
b[n]   //Vetor que contém a cadeia de caracteres no código binário
XOR(bit, bit) //Função Ou exclusivo
```

```
Função_Binário_Para_Gray(){
    i=1;
    G[i]=b[i];
    Enquanto (i≠n) {
        i=i+1;
        G[i]=XOR(b[i - 1],b[i]);
    }
}
```

```
Função_Gray_Para_Binário(){
    i=1;
    b[i]=G[i];
    Enquanto (i≠n) {
        i=i+1;
        b[i]=XOR(b[i - 1],G[i]);
    }
}
```

Algoritmos Genéticos - Representação

15

- Representação binária:
 - ▣ Tem **dificuldades** com múltiplas dimensões de **variáveis contínuas**, especialmente quando uma grande precisão é requerida.
 - **Grande número de bits** será necessário para atingir tal precisão.
 - **Cromossomos** se tornarão **extremamente grandes**, dificultando a operação do algoritmo genético.

Algoritmos Genéticos - Representação

16

□ Codificação Real

- Tem sido cada vez mais usada em problemas de otimização com variáveis de decisão **contínuas**.
- Representação direta, o genótipo do indivíduo é o próprio vetor de variáveis de decisão.
- $\mathbf{X} = (x_1, x_2, \dots, x_n)$, onde n = número de variáveis de decisão.
 - Exemplo de indivíduo: $\mathbf{X} = (0,34 \ 9,71 \ 3,45)$
- Resultados empíricos indicam que, para problemas com variáveis **contínuas**, a **codificação real é superior** às outras.

Algoritmos Genéticos - Geração Inicial


17

- Inicialização **aleatória** é o padrão.
- Há tentativas de gerar algo mais inteligente, porém há o risco de causar **convergência prematura**.
- Além disso, pode ser difícil gerar soluções boas e variadas, que é o desejado.
- Exemplos:
 - ▣ Codificação real:
 - Para cada variável de decisão deve-se gerar um valor aleatório válido dentro do domínio permitido.
 - ▣ Codificação binária:
 - Basta gerar aleatoriamente $npop$ indivíduos.
 - Cada indivíduo é composto por n cadeias de bits 0 e 1. Cada cadeia possui l_i bits.

Algoritmos Genéticos – Tamanho da População

18

- Deve-se escolher o número de indivíduos da população.
 - ▣ De acordo com as características do problema. Em geral, **usam-se dezenas ou centenas de indivíduos**.
 - População pequena tem diversidade insuficiente e pode convergir prematuramente.
 - População grande pode não ter tempo suficiente de evoluir.



Fonte: Referência (2).

Função Fitness

19

- É a maneira utilizada pelos algoritmos genéticos para determinar a **qualidade de um indivíduo** como solução do problema em questão.
- Também chamada de função de mérito, função de desempenho, função de avaliação ou função de aptidão.
- É usada para a escolha dos indivíduos na **etapa de seleção**.
- Fornece uma **nota** a cada **indivíduo** considerando sua capacidade de resolução do problema.
- Baseia-se na **função objetivo** do modelo de otimização.
- Deve **diferenciar entre duas soluções subótimas**.

Referências Bibliográficas

20

- Principais referências bibliográficas desta aula:
 - ▣ 1) João A. Vasconcelos. Notas de aula. UFMG, 2011.
 - ▣ 2) Joshua Knowles. Notas de aula. University of Manchester, 2014.